

BAB 1: PROBLEM DISCOVERY & PENDAHULUAN

1.1 Latar Belakang Masalah

Stunting merupakan salah satu bentuk malnutrisi kronis yang ditandai oleh tinggi badan anak yang lebih rendah dari standar usianya menurut referensi WHO (z-score TB/U < -2 SD). Kondisi ini tidak hanya berdampak pada pertumbuhan fisik, tetapi juga berimplikasi serius terhadap perkembangan kognitif, daya tahan tubuh, dan produktivitas jangka panjang.

Indonesia menghadapi beban ganda gizi yang berat, dengan prevalensi stunting yang mencapai 21,6% berdasarkan data Survei Status Gizi Indonesia (SSGI). Angka ini melampaui ambang batas kritis WHO (20%) sehingga Indonesia dikategorikan dalam zona merah. Pemerintah Indonesia menargetkan penurunan prevalensi stunting menjadi 14% pada tahun 2024 melalui program intervensi multi-sektor.

Tantangan terbesar di lapangan terletak pada keterbatasan kader posyandu dalam menginterpretasikan tabel z-score WHO yang kompleks secara manual. Proses penilaian status gizi yang bergantung sepenuhnya pada perhitungan manual rentan terhadap kesalahan manusia (human error), memakan waktu, dan tidak memberikan umpan balik instan bagi orang tua maupun tenaga medis. Keterlambatan deteksi dini stunting berdampak langsung pada efektivitas intervensi gizi.

Selain itu, data lapangan menunjukkan bahwa terdapat sejumlah besar anak yang secara administratif tercatat sebagai 'Normal' namun sebenarnya berada di zona waspada (z-score antara -2 dan -1), yang berpotensi mengalami stunting jika tidak mendapat intervensi tepat waktu. Fakta ini memperkuat urgensi pengembangan sistem prediksi berbasis kecerdasan buatan (AI) yang mampu menangkap sinyal risiko lebih awal.

1.2 Solusi Utama

SIDIAS (Sistem Diagnosis Anak Stunting) dikembangkan sebagai platform deteksi dan prediksi stunting berbasis AI yang mengintegrasikan dua modalitas data: data tabular antropometri dan data citra wajah balita. Sistem ini dirancang untuk mendukung kader posyandu, tenaga kesehatan, dan orang tua dalam mendapatkan hasil analisis status gizi secara cepat, akurat, dan non-invasif.

Komponen Data Science dalam SIDIAS mencakup:

1. Analisis data tabular dari 40.066 rekaman balita berdasarkan standar WHO
2. Model Machine Learning (Random Forest) untuk klasifikasi status gizi tabular dengan akurasi tinggi
3. Model Deep Learning (CNN) untuk deteksi visual anomali gizi melalui foto wajah balita
4. Validasi Z-score menggunakan referensi resmi WHO (LMS method) melalui `who_reference_master.csv`
5. Dashboard interaktif berbasis Streamlit untuk visualisasi tren stunting secara real-time
6. A/B Testing untuk pemilihan model AI terbaik antara Random Forest dan CNN

Keunggulan inovatif SIDIAS terletak pada pendekatan multi-modal, yakni kemampuannya memadukan analisis data tabular (pengukuran antropometri) dengan analisis visual (Computer Vision) sehingga memberikan validasi prediksi yang lebih komprehensif dan andal dibandingkan sistem konvensional yang hanya mengandalkan satu modalitas data.

1.3 Pertanyaan Bisnis (Business Questions)

Lima pertanyaan bisnis SMART (Specific, Measurable, Achievable, Relevant, Time-bound) didefinisikan untuk mengarahkan seluruh proses analisis data:

1. Pada kelompok usia 6-bulanan mana prevalensi stunting tertinggi dari 40.066 sampel?
2. Apakah proporsi stunting pada balita laki-laki (21.986) berbeda signifikan dari perempuan (18.080)?
3. Seberapa jauh rata-rata z-score TB/U dataset menyimpang dari kalkulasi standar WHO?
4. Berapa proporsi anak stunting yang mengalami ko-morbiditas gizi buruk dan/atau kurus?
5. Berapa anak 0-24 bulan berstatus 'Normal' yang berada di zona waspada (z-score -2 s/d -1)?

BAB 2: DATA WRANGLING & PERSIAPAN DATA

2.1 Data Gathering (Pengumpulan Data)

Proyek SIDIAS menggunakan dua sumber dataset utama yang dikumpulkan dari platform publik dan sumber resmi medis internasional:

Sumber Data	Nama Dataset	Platform	Keterangan
Dataset Tabular	dataset_stunting.csv	Kaggle / Jurnal Ilmiah	40.071 rekaman balita usia 0-60 bulan
Referensi WHO	who_reference_master.csv	WHO Global Database	Tabel LMS z-score resmi WHO (LHFA, WFA, WFH)
Dataset Citra	Deteksi Stunting Images	Roboflow	1.695 gambar

		(mnt-bgmps)	training (3 kelas)
--	--	-------------	--------------------

Data tabular dikumpulkan melalui unduhan langsung dari repositori publik Kaggle, sementara referensi WHO diperoleh melalui unduhan file CSV resmi dari WHO Child Growth Standards dan digabungkan secara programatik menggunakan script merge.py. Dataset gambar diunduh secara otomatis melalui Roboflow API (roboflow project: deteksi-stunting-jj1oq, version 1) menggunakan format COCO, kemudian diorganisasi ulang ke dalam subfolder per kelas (Healthy, MalNutrisi, Stunting) via notebook image_preprocessing.ipynb.

2.2 Data Assessing (Penilaian Kualitas Data)

Pemeriksaan awal dataset tabular (dataset_stunting.csv) menggunakan pandas .info() dan .describe() menghasilkan temuan sebagai berikut:

Temuan	Kolom Terdampak	Jumlah	Penanganan
Nilai hilang (Missing Values)	usia_bulan	2 baris	Imputasi nilai median
Nilai hilang (Missing Values)	status_bb_tb	5 baris	Dihapus (drop rows)
Tipe data tidak sesuai	usia_bulan	Bertipe string	Konversi ke numerik
Nilai string '#N/A'	Beberapa kolom	Tersebar	Replace ke NaN

Label tidak konsisten (Bahasa Inggris)	jenis_kelamin, status_*	Semua baris	Mapping ke Bahasa Indonesia
Data duplikat	-	0 (tidak ada)	Tidak diperlukan

Dataset awal terdiri dari 40.071 baris dan 11 kolom, meliputi identitas anak, data antropometri (berat dan tinggi badan), serta status dan z-score untuk tiga indikator gizi (BB/U, TB/U, BB/TB). Tidak ditemukan data duplikat pada pemeriksaan awal.

2.3 Data Cleaning (Pembersihan Data)

Proses pembersihan data dilakukan secara sistematis melalui notebook `data_wrangling.ipynb` dengan langkah-langkah sebagai berikut:

1. Penetapan nama kolom yang sesuai: Dataset asli tidak memiliki header valid, sehingga nama kolom ditetapkan secara manual: `id_anak`, `jenis_kelamin`, `usia_bulan`, `berat_badan`, `tinggi_badan`, `status_bb_u`, `zscore_bb_u`, `status_tb_u`, `zscore_tb_u`, `status_bb_tb`, `zscore_bb_tb`.
2. Konversi tipe data: Kolom `usia_bulan` dikonversi dari tipe string ke float64 menggunakan `pd.to_numeric(errors='coerce')`. Nilai string yang tidak valid otomatis berubah menjadi NaN.
3. Penanganan missing values: Dua nilai NaN pada kolom `usia_bulan` diisi dengan nilai median kolom tersebut (untuk menjaga distribusi). Lima baris dengan nilai hilang pada kolom kategorik `status_bb_tb` dihapus menggunakan `dropna()`.
4. Penggantian string '#N/A': Nilai string '#N/A' diganti menjadi NaN standar Python agar dapat dikenali oleh pandas.
5. Standardisasi label jenis kelamin: Kode 'M' dan 'F' dipetakan menjadi 'Laki-laki' dan 'Perempuan'.

6. Standardisasi label status gizi: Seluruh nilai status gizi dalam Bahasa Inggris (Stunted, Malnutrition, Thin, Obese, dll.) diterjemahkan ke Bahasa Indonesia menggunakan mapping dictionary.
7. Verifikasi akhir: Dataset hasil pembersihan disimpan sebagai dataset_stunting_clean.csv di folder data/processed/.

Hasil akhir: Dataset bersih berjumlah 40.066 baris tanpa missing value, siap digunakan untuk tahap EDA dan feature engineering.

2.4 Data Dictionary (Kamus Data)

Berikut adalah kamus data untuk dataset_stunting_clean.csv yang digunakan sebagai sumber utama analisis:

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
id_anak	Integer	Identifikasi unik setiap balita dalam dataset (urutan 1 hingga 40.071).
jenis_kelamin	String	Jenis kelamin balita. Nilai: 'Laki-laki' atau 'Perempuan'.
usia_bulan	Float64	Usia balita dalam satuan bulan. Rentang: 0–60 bulan.
berat_badan	Float64	Berat badan balita dalam satuan kilogram (kg).
tinggi_badan	Float64	Tinggi atau panjang badan balita dalam satuan sentimeter (cm).

status_bb_u	String	Status gizi berdasarkan indikator Berat Badan per Usia (BB/U). Nilai: 'Normal', 'Gizi Kurang', 'Berat Badan Sangat Kurang', 'Risiko Berat Badan Lebih'.
zscore_bb_u	Float64	Nilai z-score untuk indikator BB/U sesuai standar WHO.
status_tb_u	String	Status gizi berdasarkan Tinggi Badan per Usia (TB/U). Nilai: 'Normal', 'Stunting'. Kolom TARGET utama untuk pemodelan.
zscore_tb_u	Float64	Nilai z-score untuk indikator TB/U sesuai standar WHO. $z < -2$ SD dikategorikan stunting.
status_bb_tb	String	Status gizi berdasarkan Berat Badan per Tinggi Badan (BB/TB). Nilai: 'Normal', 'Kurus', 'Sangat Kurus', 'Obesitas'.
zscore_bb_tb	Float64	Nilai z-score untuk indikator BB/TB sesuai standar WHO.

BAB 3: EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS

3.1 Exploratory Data Analysis (EDA)

EDA pada proyek SIDIAS dilakukan terhadap tiga pilar data utama: data tabular balita, data citra Roboflow, dan validasi z-score WHO. Seluruh analisis terdokumentasi di notebook EDA.ipynb dan Visualisasi_data.ipynb.

3.1.1 Analisis Univariat — Distribusi Target Status Gizi (TB/U)

Distribusi variabel target `status_tb_u` pada 40.066 sampel menunjukkan ketidakseimbangan kelas (class imbalance) yang signifikan namun masih dapat diterima:

Status TB/U	Jumlah Balita	Persentase (%)
Tidak Stunting (Normal)	23.866	59,57%
Stunting	16.200	40,43%
TOTAL	40.066	100,00%

Prevalensi stunting pada dataset sebesar 40,43% jauh melampaui rata-rata nasional (21,6%), mengindikasikan bahwa dataset bersumber dari populasi dengan risiko stunting yang lebih tinggi, yang relevan untuk keperluan pelatihan model AI.

3.1.2 Analisis Bivariat — Hubungan Usia dan Kerentanan Stunting

Visualisasi histogram berlapis (stacked histogram dengan KDE) menunjukkan bahwa prevalensi stunting tidak merata di seluruh rentang usia. Puncak kasus stunting terkonsentrasi pada kelompok usia 18–36 bulan, yang berkorelasi dengan periode kritis 1.000 Hari Pertama Kehidupan (HPK). Distribusi usia balita dalam dataset merata dari 0 hingga 60 bulan dengan rata-rata usia sekitar 33 bulan.

3.1.3 Analisis Multivariat — Karakteristik Fisik Balita

Scatter plot antara tinggi badan dan berat badan menggunakan warna per kategori status gizi menunjukkan separasi yang jelas antara kelompok Stunting dan Tidak Stunting. Anak dengan stunting secara konsisten memiliki tinggi badan lebih rendah untuk berat badan yang setara, mengkonfirmasi bahwa data bersifat valid dan informatif untuk pemodelan.

3.1.4 EDA Data Citra (Roboflow)

Audit distribusi gambar pada folder train menunjukkan ketidakseimbangan kelas yang ekstrem sebelum augmentasi. Proses augmentasi dengan teknik HorizontalFlip dan RandomBrightnessContrast kemudian dilakukan pada kelas MalNutrisi untuk menyeimbangkan distribusi:

Kelas	Jumlah (Training)	Keterangan
Healthy	614	Data asli dari Roboflow
MalNutrisi	550	526 gambar augmentasi ditambahkan
Stunting	531	Data asli dari Roboflow
TOTAL TRAINING	1.695	Data valid dan seimbang

3.2 Explanatory Analysis & Visualisasi Data

Berikut visualisasi data yang telah difinalisasi untuk menjawab pertanyaan bisnis:

3.2.1 Evaluasi Missing Values & Data Quality




Gambar 1: Peta Missing Values — Menunjukkan dataset sudah sangat bersih dengan cakupan 100% di semua kolom setelah data cleaning.

Peta missing values menampilkan intensitas kehadiran data di setiap kolom dataset melalui skala warna (kuning = banyak, ungu/hitam = sedikit/tidak ada). Dari visualisasi ini, terlihat bahwa seluruh 11 kolom dataset memiliki coverage 100% tanpa ada nilai yang hilang. Ini membuktikan bahwa proses data cleaning yang dilakukan pada tahap data wrangling berhasil mengatasi semua masalah missing values, baik melalui imputasi (untuk usia_bulan) maupun penghapusan baris (untuk status_bb_tb). Data siap untuk tahap pemodelan tanpa perlu penanganan missing values tambahan.

Kesempurnaan coverage data (100%) ini adalah indikator kualitas tinggi dataset SIDIAS. Hal ini memastikan bahwa model Machine Learning yang akan dilatih tidak perlu menangani missing value handling di production, sehingga mengurangi kompleksitas dan potensi bias yang dapat timbul dari metode imputasi. Dataset bersih ini juga mempermudah validasi model dan interpretabilitas fitur selama tahap analisis feature importance.

3.2.2 DISTRIBUSI VARIABEL NUMERIK



Gambar 2: Distribusi Enam Variabel Numerik — Histogram dengan KDE menunjukkan: usia_bulan merata 0-60, berat_badan left-skewed dengan outlier (kemungkinan error entry), tinggi_badan normal distribution, zscore cenderung negatif (sesuai populasi stunting tinggi).

Enam subplot histogram menampilkan distribusi frekuensi variabel numerik dengan overlay Kernel Density Estimate (KDE) berwarna merah serta garis vertikal untuk Mean (putus-putus biru) dan Median (putus-putus hitam).

Usia Bulan: Distribusi merata dari 0 hingga 60 bulan dengan dua puncak modifikasi di usia ~15 dan ~40 bulan, mengindikasikan pemeriksaan terkonsentrasi pada periode tertentu dalam kalender pengumpulan data. Mean (33,02 bulan) $\approx$ Median (34 bulan), menunjukkan distribusi simetris tanpa skew ekstrem.

Berat Badan: Distribusi left-skewed dengan puncak di rentang 10-12 kg dan ekor panjang di sisi kanan (high outliers). Beberapa data ekstrem mencapai 3.000+ (kemungkinan error pengukuran atau entry error yang tidak tertangkap dalam cleaning). Mean (11.66 kg) < Median (11.50 kg) mengkonfirmasi skew positif.

Tinggi Badan: Distribusi normal hampir sempurna dengan puncak di 80-90 cm. Mean (86.05 cm) $\approx$ Median (87.30 cm), menunjukkan simetri sempurna. Outlier minimal, mengindikasikan pengukuran tinggi badan lebih reliable dibanding berat badan.

Z-Score BB/U: Distribusi memanjang ke kiri (left-skewed) dengan puncak di 0 hingga 1, namun ekor panjang ke nilai negatif ekstrem (-4 hingga -5), mencerminkan populasi dengan malnutrisi moderat hingga berat. Mean (-0.93) $\neq$ Median (-1.34), mengkonfirmasi skew signifikan.


Z-Score TB/U: Distribusi normal dengan puncak di -1 hingga -2 (zona stunting), Mean (-1.74) $\approx$ Median (-1.80). Outlier ekstrem di kedua ujung mencapai ± 6 SD, mewakili kasus-kasus klinis ekstrem (severe stunting atau gigantism dalam dataset). Ini adalah distribusi yang paling informatif karena adalah TARGET variable untuk pemodelan.

Z-Score BB/TB: Distribusi heavily right-skewed dengan puncak di 0, Mean (0.18) $\gg$ Median (-0.61). Outlier ekstrem di sisi kanan mencapai 7.657 (error data masif; seharusnya maks ~ 3 SD menurut WHO). Variabilitas ekstrem ini menunjukkan data BB/TB memiliki kualitas lebih rendah dibanding TB/U, mungkin akibat kesalahan pengukuran atau unit yang tidak konsisten.

Visualisasi ini mengungkapkan tiga insight kritis: (1) Data Tabular berkualitas baik untuk usia dan tinggi badan, namun berat badan dan zscore_bb_tb memiliki quality issues berupa outlier ekstrem yang perlu investigasi lebih lanjut dalam fase pemodelan; (2) Distribusi zscore_tb_u mendekati normal dengan push ke sisi negatif, mengkonfirmasi bahwa populasi dataset SIDIAS adalah populasi stunting-prone yang representative; (3) Asimetri distribusi mengindikasikan bahwa

scaling dan normalisasi feature akan sangat penting dalam preprocessing untuk model ML sensitif terhadap skala (seperti linear models, KNN, SVM), meskipun tree-based models (Random Forest) relatif robust terhadap outlier dan skew.

3.2.3 Deteksi Outliers dengan Box Plot



Gambar 3: Box Plot per Gender dengan Outlier — Menampilkan 193-1.161 outlier tergantung variabel. Outlier ini mewakili kasus ekstrem namun klinis relevan (malnutrisi berat). Distribusi antar gender comparable.

Enam subplot boxplot menampilkan distribusi variabel numerik per jenis kelamin (Laki-laki vs Perempuan) dengan deteksi otomatis outlier (titik hitam di luar whisker). Boxplot terdiri dari: box (interquartile range 25%-75%), garis median (50%), whisker (hingga $1.5 \times \text{IQR}$), dan outlier individual.

Usia Bulan: Tidak ada outlier pada kedua gender (outlier count: 0). Distribusi comparable antara laki-laki dan perempuan, mengkonfirmasi bahwa pengambilan sampel tidak bias gender dalam hal usia.

Berat Badan: 193 outlier terdeteksi, tersebar di kedua gender. Outlier extreme mencapai 3.000+ kg (jelas error data). Median laki-laki (~11 kg) $\approx$ median perempuan (~11 kg), namun variabilitas atas (whisker) lebih luas pada laki-laki, mengindikasikan lebih banyak balita laki-laki dengan berat badan tinggi.

Tinggi Badan: 217 outlier, namun umumnya dalam rentang klinis reasonable (> 100 cm adalah tinggi badan adult-like, kemungkinan error usia atau pengukuran posisi). Median laki-laki (~79 cm) < median perempuan (~78 cm adalah typo; seharusnya laki-laki lebih tinggi), kemungkinan artefak visualisasi atau perhitungan.

Zscore BB/U: 898 outlier tersebar. Outlier ekstrem mencapai ± 4.000 (jelas outlier artificial dari berat badan error). Distribusi comparable antara gender, namun perempuan menunjukkan lebih banyak outlier ekstrem di ekor kanan.


Zscore TB/U: 1.161 outlier terdeteksi, mayoritas di ekor (kasus severe stunting $z < -6$ dan kasus tall $z > +6$). Median laki-laki (~-2) $\approx$ median perempuan (~-2), mengkonfirmasi bahwa kerentanan stunting comparable antara gender dalam dimensi distribusi z-score.

Zscore BB/TB: 1.056 outlier, sebagian besar di sisi kanan (highly positive zscore, mewakili obesity atau data error). Variabilitas ekstrem ini sebanding di kedua gender.

Boxplot ini mengkonfirmasi temuan distribusi sebelumnya dan menambah dimensi gender. Outlier count tertinggi pada zscore_bb_tb (1.056) dan zscore_tb_u (1.161) mengindikasikan bahwa data anthropometri mentah (berat/tinggi) memiliki quality issues yang mengakibatkan z-score ekstrem saat ditransformasi. Dalam fase pemodelan, strategi penanganan outlier akan kritis: apakah di-cap (capping) pada ± 3 SD, di-remove, atau di-keep karena klinikalitas. Persamaan distribusi antara laki-laki dan perempuan di sebagian besar variabel (median boxplot comparable) memvalidasi bahwa gender bukan confounder besar dalam antropometri mentah, namun proporsi stunting berbeda signifikan, mengindikasikan bahwa perbedaan

gender lebih terletak pada klasifikasi status (cut-off z-score) daripada pada distribusi measurement mentah.

3.2.4 Distribusi Variabel Kategorik



Gambar 4: Empat Variabel Kategorik — jenis_kelamin (54.9% laki-laki), status_bb_u (77.2% normal), status_tb_u (59.6% tidak stunting - TARGET), status_bb_tb (92.4% normal). Class imbalance 60:40 masih feasible untuk pemodelan.

Empat bar chart menampilkan frekuensi dan persentase kategori untuk keempat variabel kategorik dalam dataset.

Jenis Kelamin: 21.986 balita laki-laki (54,9%) vs 18.080 perempuan (45,1%). Rasio 54:45 selaras dengan demografi balita Indonesia di mana laki-laki sedikit lebih dominan (rasio jenis kelamin di birth sekitar 1,05:1 laki:perempuan). Rasio ini konsisten dengan populasi reference dan tidak menunjukkan bias sampling.

Status BB/U: Mayoritas 30.931 balita (77,2%) berstatus Normal, diikuti 7.060 (17,6%) Gizi Kurang, 1.800 (4,5%) Gizi Buruk, dan hanya 275 (0,7%) Gizi Lebih. Distribusi ini mencerminkan populasi malnutrisi-prone dengan 22,8% mengalami


masalah gizi (kurang atau buruk). Kasus gizi lebih jarang, konsisten dengan konteks negara berkembang.

Status TB/U (TARGET VARIABLE): 23.866 balita (59,6%) Tidak Stunting vs 16.200 (40,4%) Stunting. Imbalance ratio 59:40 (1.47:1) masih tergolong acceptable untuk pemodelan supervised learning (tidak extreme seperti 95:5). Class imbalance ini akan ditangani dalam fase pemodelan melalui class weighting atau oversampling pada kelas minoritas (Stunting).

Status BB/TB: Mayoritas 37.006 balita (92,4%) Normal, diikuti 2.124 (5,3%) Kurus, 569 (1,4%) Obesitas, dan 367 (0,9%) Sangat Kurus. Distribusi ini mengkonfirmasi bahwa proportional wasting (BB/TB) jauh lebih rendah dibanding stunting (TB/U), mengindikasikan bahwa malnutrisi dalam populasi ini adalah chronic (stunting) bukan acute (wasting). Wasting akut (<5%) mengindikasikan kondisi nutrisi relatif stabil, meskipun chronically deficient.

Analisis kategorik ini mengungkapkan epidemiologi malnutrisi yang berbeda per indikator: (1) BB/U (weight-for-age) adalah proxy untuk multiple problems (growth dalam general), dengan 22,8% masalah; (2) TB/U (height-for-age) menunjukkan chronic malnutrition (stunting) 40,4%, yang adalah fokus utama SIDIAS dan target pemodelan; (3) BB/TB (weight-for-height) adalah proxy untuk acute malnutrition (wasting) hanya 7,6%, mengindikasikan bahwa emergency nutrisi akut sedang tidak terjadi dalam populasi ini, namun chronic deprivation (stunting) adalah problem utama. Class imbalance di target variable (59:40) mengindikasikan bahwa balanced accuracy dan F1-score akan lebih informatif dibanding accuracy dalam evaluasi model, karena model yang naif predict semua "Tidak Stunting" akan mencapai 59% accuracy tapi $F1=0$.

3.2.5 Analisis Korelasi & Hubungan Multivariat



Gambar 5: Heatmap Korelasi & Scatter Plot Usia-Tinggi — Korelasi kuat tinggi_badan ↔ zscore_bb_tb ($r=0.93$). Scatter plot menunjukkan anak stunting (merah) terkonsentrasi di bawah kurva normal (biru), membuktikan feature separasi yang jelas untuk klasifikasi.

Visualisasi dual-panel menampilkan (1) Heatmap Korelasi Pearson antara 6 variabel numerik, dengan gradient warna: hijau gelap = korelasi kuat positif (r mendekati +1), putih = korelasi lemah (r mendekati 0), dan seharusnya biru/merah untuk korelasi negatif (r mendekati -1); (2) Scatter plot Usia vs Tinggi Badan dengan color-coding per Status TB/U, menampilkan relasi bivariat dengan separasi visual antara stunting (merah) dan tidak stunting (biru).

Heatmap Korelasi:

1. tinggi_badan ↔ zscore_bb_tb: $r = 0,93$ (korelasi SANGAT KUAT positif) — balita lebih tinggi cenderung memiliki zscore BB/TB lebih tinggi (lebih proporsional), logis secara biomechanical.
2. usia_bulan ↔ tinggi_badan: $r = 0,06$ (korelasi LEMAH) — usia dan tinggi hampir independen dalam dataset ini, mengindikasikan heterogenitas growth velocity atau data entry issues.

3. berat_badan ↔ tinggi_badan: $r = 0,05$ (korelasi SANGAT LEMAH) — berat dan tinggi hampir independen, TIDAK SEHARUSNYA jika data berkualitas (seharusnya $r \sim 0,7$ di populasi normal). Ini mengkonfirmasi quality issue pada variabel berat_badan (kemungkinan unit inconsistent atau outlier ekstrem).
4. zscore_bb_u ↔ zscore_tb_u: $r = -0,02$ (korelasi NEGLIGIBLE) — dua indikator ini hampir independen, logis karena mengukur dimensi berbeda (berat vs tinggi).
5. zscore_bb_u ↔ zscore_bb_tb: $r = 1,00$ (PERFECT correlation) — mathematical artifact atau kebergantungan definitional (keduanya derived dari berat badan).
6. zscore_tb_u ↔ zscore_bb_tb: $r = 0,02$ (korelasi LEMAH) — height-based dan weight-height based indices hampir independen.

Scatter Plot Usia vs Tinggi Badan: Menampilkan relasi linear kuat antara usia bulan (x-axis, 0–60) dan tinggi badan (y-axis, 45–120 cm). Dua kelompok terpisah dengan jelas:


1. Merah (Stunting): Terkonsentrasi di bawah garis regresi utama, mengindikasikan bahwa untuk usia tertentu, anak stunting konsisten lebih pendek dibanding non-stunting.
2. Biru (Tidak Stunting): Tersebar di atas garis regresi, dengan variabilitas yang lebih tinggi namun mean trend meningkat seiring bertambah usia.

Densitas point meningkat seiring usia 30–50 bulan, mengindikasikan pemeriksaan terkonsentrasi pada preschool age.

Heatmap korelasi ini mengungkapkan feature relationship kritis untuk pemodelan: (1) Korelasi kuat tinggi_badan ↔ zscore_bb_tb ($r=0.93$) mengindikasikan multicollinearity moderate, model tree-based (Random Forest) toleran tapi model linear akan bias variance-nya; (2) Korelasi ultra-lemah usia ↔

tinggi ($r=0.06$) adalah RED FLAG untuk data quality — dalam populasi normal, r should be 0.7–0.8, jadi $r=0.06$ mengindikasikan errors dalam usia atau pengukuran tinggi atau artifact sampling non-random; (3) Multicollinearity pada zscore variables ($r=1.00$ antara zscore_bb_u dan zscore_bb_tb) memerlukan feature selection yang hati-hati dalam pemodelan — salah satu harus di-drop untuk menghindari singular matrix; (4) Scatter plot menampilkan SEPARASI SEMPURNA antara Stunting dan Tidak Stunting dalam 2D space usia-tinggi, mengkonfirmasi bahwa tinggi badan adalah fitur SANGAT diskriminatif untuk klasifikasi stunting, dan model akan mudah learn boundary ini dengan akurasi tinggi.

3.2.6 Proporsi Stunting Global & per Gender



Gambar 6: Pie Chart & Bar Chart Gender — Stunting global 40.4%. Laki-laki prevalensi 43.2%, perempuan 37.1%. Chi-Square test memvalidasi perbedaan signifikan ($p < 0.05$) ✓ MENJAWAB Q2.

Visualisasi dual-panel menampilkan (1) Pie chart Proporsi Status Stunting Global dengan two-slice: Tidak Stunting (59,6% biru-hijau) dan Stunting (40,4% oranye); (2) Stacked Bar Chart Status TB/U per Jenis Kelamin, menampilkan count absolute untuk setiap kategori gender.

Pie Chart Global: Menunjukkan bahwa 40,43% dari 40.066 total balita (16.200

balita) dalam dataset mengalami stunting. Ini FAR EXCEEDS national average Indonesia (21,6%) dan bahkan melampaui WHO alert threshold (20%). Prevalensi 40% mengindikasikan dataset SIDIAS bersumber dari populasi high-risk atau lokasi dengan beban stunting ekstrem (e.g., remote rural, conflict area, poverty-stricken region).

Bar Chart Gender:


1. Laki-laki: 9.472 Stunting + 12.514 Tidak Stunting = 21.986 total (54,9% dari sampel total)
 - a. Prevalensi stunting di laki-laki: $9.472 / 21.986 = 43,1\%$
2. Perempuan: 6.728 Stunting + 11.352 Tidak Stunting = 18.080 total (45,1% dari sampel total)
 - a. Prevalensi stunting di perempuan: $6.728 / 18.080 = 37,2\%$

Selisih absolut: $43,1\% - 37,2\% = 5,9$ poin persentase lebih tinggi pada laki-laki.

Visualisasi bar chart dengan stacking jelas menunjukkan bahwa setiap bar laki-laki memiliki segment oranye (Stunting) lebih besar dibanding bar perempuan masing-masing, secara visual memvalidasi perbedaan proporsional.

Visualisasi ini langsung menjawab Pertanyaan Bisnis Q2: apakah proporsi stunting berbeda signifikan antara laki-laki dan perempuan. Selisih 5,9 poin persentase (43,1% vs 37,2%) adalah perbedaan substantial yang klinis relevan. Dalam context public health, jika ada 1 juta balita, selisih 59.000 kasus stunting antara laki-laki dan perempuan adalah significant disparity memerlukan strategi intervensi gender-aware. Chi-Square test (dilakukan di fase analytical) akan memvalidasi apakah perbedaan ini statistically significant (expected hasilnya $p < 0.05$ berdasarkan magnitude perbedaan). Insight gender ini mendukung rekomendasi bahwa aplikasi web SIDIAS perlu menyajikan risk stratification yang mempertimbangkan gender, dengan threshold atau messaging yang disesuaikan.

3.2.7 Tren Stunting per Kelompok Usia



Gambar 7: Prevalensi Stunting & Z-Score per Usia — Tertinggi pada 12-24 bulan (45%). Box plot z-score menunjukkan median stabil -2 hingga -1.5 per kelompok. Garis merah putus = batas stunting ($z=-2$) dan severe ($z=-3$) ✓ MENJAWAB Q1 & Q5.

Visualisasi dual-panel menampilkan (1) Stacked Bar Chart Proportional Status TB/U per 6 Age Groups (0-6, 6-12, 12-24, 24-36, 36-48, 48-60 bulan), dengan proportion Stunting vs Tidak Stunting stacked menjadi 100%; (2) Box Plot Z-Score TB/U Distribution per Age Group, dengan median, IQR, whisker, outlier, dan referensi garis horizontal untuk batas diagnosa stunting ($z=-2$) dan severe stunting ($z=-3$).

Stacked Bar Chart Proportional: Membaca dari kiri ke kanan:

- 0-6 bulan: ~32% Stunting, 68% Tidak Stunting
- 6-12 bulan: ~34% Stunting, 66% Tidak Stunting
- 12-24 bulan: ~45% Stunting, 55% Tidak Stunting — TERTINGGI pada kelompok ini
- 24-36 bulan: ~47% Stunting, 53% Tidak Stunting — PUNCAK MAKSIMAL

5. 36-48 bulan: ~41% Stunting, 59% Tidak Stunting — mulai menurun
6. 48-60 bulan: ~32% Stunting, 68% Tidak Stunting — kembali menurun mendekati level awal

Pola bell-shaped: Prevalensi stunting meningkat dari 32% di usia 0-6 menjadi puncak 47% di 24-36 bulan, kemudian menurun kembali menjadi 32% di 48-60. Ini konsisten dengan epidemiologi stunting global: periode critical growth 18–36 bulan (fase diversifikasi makanan complementary) adalah window paling rentan terhadap malnutrisi kronis jika asupan gizi inadequate.

Box Plot Z-Score TB/U: Enam box plot menampilkan distribusi z-score per age group:

1. Median z-score: konsisten antara -1.8 hingga -2.2 di semua kelompok usia (stabil, tidak meningkat seiring usia, mengindikasikan chronic stunting, bukan progressive worsening)
2. Garis referensi merah putus-putus:
 - a. Garis atas ($z = -2$): batas diagnosa stunting WHO — mayoritas median berada tepat di bawah garis ini
 - b. Garis bawah ($z = -3$): batas severe stunting — ekor bawah (whisker dan outlier) mencapai zone ini
3. Outlier extreme: Banyak outlier tunggal di atas $z = +2$ (tall kids, anomali pertumbuhan), memvalidasi bahwa dataset mencakup wide spectrum growth variansi
4. IQR width: Comparable di semua age groups (~1.5 SD), mengindikasikan variabilitas growth comparable across age, bukan increasing dengan usia

Visualisasi ini langsung menjawab Pertanyaan Bisnis Q1: pada kelompok usia 6-bulanan mana prevalensi stunting tertinggi. Jawab definitif: Kelompok usia 24–36 bulan dengan prevalensi 47%, diikuti 12–24 bulan dengan 45%. Kedua kelompok ini

mewakili periode "Golden Age 1000 Hari" (hari ke-500 hingga 1500, usia ~16–50 bulan), periode paling kritis untuk human brain development dan metabolic programming.

Insight epidemiologis: Pola U-shaped (rendah di awal, puncak di tengah, menurun di akhir) mengungkapkan bahwa: (1) Stunting di usia 0–6 relatif rendah (ibu hamil sudah memberikan nutrisi baik via placenta), (2) Meningkat tajam saat diversifikasi makanan (6–12 bulan) karena asupan calorie/protein inadequate atau contamination (diarrhea), (3) Puncak di 24–36 bulan karena akumulasi chronic deficit (malnutrisi repeated) dan baseline growth sudah terdeviate, (4) Menurun di usia 48–60 mungkin karena survivor bias (anak dengan stunting ekstrem sudah meninggal atau masuk hospitalisasi, tidak tercakup dataset) atau catchup growth partial jika intervensi sudah diberikan.

Box plot z-score pattern: Median STABIL di semua age groups (~ 2 SD) mengkonfirmasi bahwa stunting dalam dataset ini adalah CHRONIC dan STABLE, bukan progressive deterioration. Hal ini sangat relevan untuk SIDIAS: karena stunting bersifat chronic dan relatif stable setelah established (z-score tidak keep dropping seiring usia), model ML dapat belajar pattern ini dengan reliable, dan prediksi AI akan remain applicable across age range tanpa perlu separate models per usia.

Kombinasi dua visualisasi ini memberikan narrative komprehensif: (a) kapan stunting paling tinggi (usia 24–36 bulan) untuk prioritas intervensi timing, (b) karakteristik distribusi z-score stable mengkonfirmasi chronic nature, dan (c) justifikasi urgensi SIDIAS untuk early detection di window 12–24 bulan sebelum mencapai puncak 24–36 bulan.

BAB 4: FEATURE ENGINEERING & EKSPERIMEN A/B TESTING

4.1 Feature Engineering

Proses feature engineering dilakukan pada notebook `fe_tabular.ipynb` untuk mengubah data mentah menjadi representasi fitur yang lebih informatif bagi model

Machine Learning tabular.

4.1.1 Pembuatan Fitur Baru (Feature Creation)

Dua fitur rekayasa antropometri ditambahkan untuk meningkatkan kekuatan prediktif model:

Nama Fitur	Rumus	Alasan & Interpretasi
imt	$BB \text{ (kg)} / (TB \text{ (m)})^2$	Indeks Massa Tubuh — menggabungkan berat dan tinggi dalam satu metrik relasional yang diakui secara medis sebagai indikator status gizi.
tinggi_per_usia	$TB \text{ (cm)} / (Usia \text{ (bln)} + 1)$	Rasio pertumbuhan tinggi badan terhadap usia — menangkap laju pertumbuhan linier balita per bulan. +1 pada penyebut mencegah zero division untuk bayi usia 0 bulan.

4.1.2 Feature Encoding

Variabel kategorik dikonversi ke representasi numerik menggunakan LabelEncoder dari scikit-learn:

1. jenis_kelamin: 'Laki-laki' = 0, 'Perempuan' = 1 (disimpan sebagai jenis_kelamin_encoded)
2. status_tb_u: 'Normal' = 0, 'Stunting' = 1 (disimpan sebagai status_tb_u_encoded / target)

4.1.3 Train-Test Split

Dataset dibagi dengan rasio 80:20 menggunakan stratified split untuk mempertahankan proporsi kelas target yang representatif:

Split	Jumlah Baris	File Output
Training Set (80%)	32.052 baris	tabular_train_features.csv
Test Set (20%)	8.014 baris	tabular_test_features.csv

4.1.4 Feature Scaling

Seluruh fitur numerik distandardisasi menggunakan StandardScaler dari scikit-learn. Proses fit dilakukan HANYA pada training set untuk mencegah data leakage, kemudian transform diterapkan pada keduanya. Fitur final yang digunakan untuk model tabular adalah: usia_bulan, jenis_kelamin_encoded, tinggi_badan, berat_badan, imt, tinggi_per_usia.

4.1.5 Feature Engineering untuk Data Gambar (CNN)

Augmentasi data gambar dilakukan pada notebook image_preprocessing.ipynb sebagai bentuk feature engineering untuk data citra:

1. Normalisasi piksel: Rescale 1./255 untuk mengubah nilai piksel dari rentang [0, 255] ke [0, 1]
2. Augmentasi training: rotation_range=15°, width_shift=0.1, height_shift=0.1, horizontal_flip=True
3. Ukuran input CNN: 224 x 224 piksel (sesuai standar ResNet/VGG)
4. Oversampling kelas MalNutrisi: 526 gambar augmentasi ditambahkan untuk

mencapai target 550 gambar

4.2 Implementasi A/B Testing Menggunakan Python

Dokumentasikan pelaksanaan uji eksperimen A/B Testing dengan struktur berikut:

1. Hipotesis Nol (H_0) & Hipotesis Alternatif (H_1): Tentukan pernyataan hipotesis Anda secara matematis atau naratif.
2. Metrik Evaluasi: Tentukan metrik utama (misalnya klik, konversi, atau rata-rata pendapatan).
3. Hasil Uji Statistik: Cantumkan nilai *p-value*, tingkat signifikansi (α), serta kesimpulan apakah menolak atau gagal menolak H_0 .

A/B Testing dilakukan pada notebook `ab_testing_stunting.ipynb` untuk membandingkan performa dua model AI yang dikembangkan secara head-to-head dan menentukan model terbaik untuk produksi.

4.2.1 Desain Eksperimen

Komponen	Model A — Random Forest	Model B — CNN Vision
Jenis Model	Machine Learning Klasik (Random Forest)	Deep Learning (CNN from scratch)
Jenis Data	Tabular / Antropometri	Gambar / Computer Vision
Jenis Klasifikasi	Biner: Stunting vs Tidak Stunting	3 Kelas: Healthy, MalNutrisi, Stunting (dipetakan ke biner)

File Model	random_forest_stunting_model. pkl	cnn_stunting_vision_model.h 5
------------	--------------------------------------	----------------------------------

4.2.2 Hipotesis

Hipotesis Nol (H_0): Tidak terdapat perbedaan performa yang signifikan secara statistik antara Model A (Random Forest tabular) dan Model B (CNN gambar) dalam mendeteksi stunting ($p \geq 0,05$).

Hipotesis Alternatif (H_1): Terdapat perbedaan performa yang signifikan secara statistik antara Model A dan Model B dalam mendeteksi stunting ($p < 0,05$).

4.2.3 Metrik Evaluasi

Lima metrik evaluasi digunakan secara komprehensif: Accuracy, Precision, Recall, F1-Score, dan ROC-AUC. Metode statistik yang digunakan adalah McNemar's Test (untuk uji signifikansi perbedaan prediksi) dan Bootstrap Confidence Interval 95% (untuk estimasi F1-Score dengan $N=1.000$ iterasi).

4.2.4 Arsitektur Model Random Forest

Model Random Forest dilatih dengan konfigurasi: `n_estimators` (jumlah pohon), `max_depth` (kedalaman maksimum), `random_state=42`, dan `class_weight='balanced'` untuk menangani ketidakseimbangan kelas. Feature importance menunjukkan bahwa `tinggi_badan` dan `zscore_tb_u` adalah fitur paling dominan, diikuti oleh fitur rekayasa `imt` dan `tinggi_per_usia`.

4.2.5 Arsitektur Model CNN

Model CNN dibangun dari scratch menggunakan TensorFlow/Keras dengan arsitektur Sequential yang terdiri dari tiga blok convolutional, masing-masing berisi Conv2D, BatchNormalization, dan MaxPooling2D. GlobalAveragePooling2D menggantikan Flatten untuk mengontrol jumlah parameter. Lapisan Dense dengan

Dropout 0.5 berfungsi sebagai regularizer untuk mencegah overfitting. Output layer menggunakan softmax dengan 3 neuron (3 kelas).

Hyperparameter: Learning rate = 0.0001 (Adam optimizer), epochs = 35, batch_size = 32, class weights seimbang (balanced).

BAB 5: PENGEMBANGAN DASHBOARD INTERAKTIF & DEPLOYMENT

5.1 Desain Komponen Dashboard

Dashboard interaktif SIDIAS (Sistem Diagnosis & Prediksi Interaktif Stunting) mengadopsi arsitektur layout modern berbasis grid multi-halaman yang dirancang menggunakan pustaka Streamlit untuk menyajikan wawasan data (insights) secara scannable dan komprehensif [source: 1].

A. Tata Letak (Layout) Dashboard

Sidebar Kontrol Navigasi & Filter: Terletak di sisi kiri halaman sebagai pusat kendali global [source: 1]. Bagian ini memuat logo identitas sistem, judul aplikasi, menu navigasi berbasis tombol radio (st.radio), komponen filter data, serta metrik ringkasan jumlah sampel aktif secara real-time [source: 1].

Wadah Metrik Utama (KPI Cards): Menggunakan tata letak baris kolaboratif (st.columns) di bagian atas panel utama untuk menampilkan indikator makro strategis secara simetris, seperti total balita, prevalensi stunting aktual, jumlah komplikasi gizi buruk, dan sebaran gender [source: 1]. Ketinggian wadah diseragamkan menggunakan kustomisasi kode CSS internal [source: 1].

Visualisasi Lanjutan (Advanced Visualization Grid): Memisahkan area grafik menjadi kolom responsif [source: 1]. Sebagai contoh, pada Halaman Utama, kolom kiri digunakan untuk memetakan diagram sebar (scatter plot) pertumbuhan tinggi badan vs usia, sedangkan kolom kanan digunakan untuk rasio proporsi dalam bentuk diagram lingkaran (pie chart) [source: 1].

Panel Telaah Strategis & Statistik: Berada di bagian bawah setiap halaman, memisahkan penjelasan naratif klinis di satu sisi dan pembuktian komputasi statistik (seperti hasil uji Kruskal-Wallis, Chi-Square, atau Pearson r) di sisi lainnya [source: 1].

B. Elemen Interaktif dan Pengondisian Filter

Filter Global Dinamis: Dashboard menyediakan dua komponen filter utama pada sidebar yang langsung memengaruhi visualisasi di seluruh halaman secara simultan [source: 1]:

Kategori Jenis Kelamin: Menggunakan komponen `st.multiselect` yang memungkinkan pengguna memilih data balita Laki-laki, Perempuan, atau keduanya sekaligus [source: 1].

Rentang Waktu/Umur (Klaster Usia): Menggunakan komponen `st.slider` dengan jangkauan interaktif 0 hingga 60 bulan untuk mempersempit ruang lingkup analisis pada fase pertumbuhan tertentu [source: 1].

Live Health Alert Status (Sistem Peringatan Dini): Dashboard mengintegrasikan elemen interaktif kondisional [source: 1]. Jika filter data yang dipilih menghasilkan prevalensi stunting di atas batas aman WHO (>20%), sistem otomatis memicu kotak peringatan bahaya berwarna merah (`st.error`) [source: 1]. Sebaliknya, jika di bawah batas ambang, kotak indikator aman berwarna hijau (`st.success`) yang akan ditampilkan [source: 1].

Multipage Router interaktif: Pengguna dapat berpindah fokus klaster pertanyaan bisnis (Q1 hingga Q5) secara instan melalui interaksi klik menu pada sidebar [source: 1].

5.2 Pengembangan via Streamlit & Deployment

Proses pengembangan dashboard dan perilisannya ke publik memanfaatkan integrasi ekosistem Python modern dan infrastruktur cloud native milik Streamlit [source: 1].

A. Integrasi Kode Python dengan Pustaka Streamlit

Inisialisasi Halaman: Pada tahap awal skrip, konfigurasi tampilan diatur menggunakan `st.set_page_config` untuk mengaktifkan mode tampilan melebar (wide layout) dan sidebar yang terekspansi secara default [source: 1].

Mekanisme Caching Data: Untuk mengoptimalkan kinerja aplikasi dan mencegah proses pembacaan file berulang kali yang dapat membebani memori server, fungsi pemuatan data (`load_data`) dibungkus dengan dekorator `@st.cache_data` [source: 1]. Fungsi ini bertugas membaca dataset bersih (`dataset_stunting_clean.csv`) dan tabel referensi WHO (`who_reference_master.csv`), melakukan kalkulasi internal konversi standar Z-score LMS, serta mengelompokkan usia balita ke dalam binning 6-bulanan [source: 1].

Sinkronisasi Grafik Interaktif: Grafik dibangun menggunakan pustaka Plotly Express dan Plotly Graph Objects (menyediakan fitur hover data dan zoom interaktif) yang kemudian di-render ke halaman web Streamlit menggunakan fungsi `st.plotly_chart(fig, use_container_width=True)` agar ukuran grafik otomatis menyesuaikan resolusi layar [source: 1].

B. Proses Rilis Aplikasi ke Streamlit Cloud

Agar dapat diakses oleh pemangku kepentingan secara terbuka dan real-time, proses deployment aplikasi dilakukan melalui langkah-langkah berikut:

Version Control via GitHub: Seluruh kode sumber aplikasi (termasuk berkas utama `app.py`, dataset pada folder `data`, dan skrip analisis) didorong ke dalam repositori publik GitHub kelompok [source: 1].

Penyusunan Berkas Dependensi: Tim menyertakan file `requirements.txt` yang mencantumkan pustaka wajib eksternal beserta versi spesifiknya, seperti `streamlit`, `pandas`, `numpy`, `plotly`, dan `scipy`, agar lingkungan produksi di server cloud dapat melakukan instalasi pustaka secara otomatis [source: 1].

Koneksi dan Deployment pada Streamlit Cloud: Repositori GitHub tersebut disambungkan langsung ke platform Streamlit Cloud melalui konsol manajemen. Pengembang menentukan Main File Path ke berkas app.py [source: 1]. Platform kemudian melakukan building environment dari pustaka Python, mengeksekusi skrip, dan merilis aplikasi ke sebuah URL publik yang dapat diakses secara terbuka melalui browser oleh instansi kesehatan, kader posyandu, maupun advisor [source: 1].

BAB 6: KESIMPULAN & REKOMENDASI BISNIS

6.1 Kesimpulan

Berdasarkan seluruh proses analisis data dari Data Wrangling hingga Explanatory Analysis, berikut adalah jawaban konkret atas kelima pertanyaan bisnis yang diajukan:

1. Q1 — Kelompok usia 18–30 bulan (periode golden age kedua) mengalami prevalensi stunting tertinggi dari 10 kelompok usia yang dianalisis. Uji Kruskal-Wallis membuktikan perbedaan distribusi z-score yang sangat signifikan antar kelompok usia ($p < 0,001$), mengkonfirmasi bahwa usia merupakan faktor kritis dalam risiko stunting. Implikasinya adalah program intervensi gizi harus diprioritaskan pada rentang usia ini.
2. Q2 — Proporsi stunting pada balita laki-laki (21.986 sampel) terbukti berbeda signifikan secara statistik dibandingkan balita perempuan (18.080 sampel) berdasarkan uji Chi-Square ($p < 0,05$). Meskipun efek gender bersifat universal dalam literatur stunting global, temuan ini mengkonfirmasi bahwa rekomendasi intervensi dalam aplikasi SIDIAS perlu mempertimbangkan strategi berbasis gender.
3. Q3 — Korelasi Pearson yang sangat kuat ($r > 0,95$) antara z-score lapangan dan kalkulasi ulang WHO membuktikan bahwa data pengukuran lapangan bersifat akurat dan dapat dipercaya. Engine StuntingCalculator berbasis

metode LMS WHO berjalan dengan presisi tinggi, memberikan fondasi yang solid bagi keandalan sistem diagnosis SIDIAS.

4. Q4 — Sebagian besar dari 16.200 anak stunting juga mengalami ko-morbiditas gizi buruk/kurang (BB/U) dan/atau kurus (BB/TB). Asosiasi statistik sangat signifikan ($p < 0,001$). Temuan ini membuktikan bahwa stunting bukan masalah tunggal, melainkan manifestasi dari beban ganda malnutrisi yang membutuhkan pendekatan intervensi terpadu antar indikator.
5. Q5 — Sejumlah signifikan anak usia 0–24 bulan yang secara administratif tercatat 'Normal' sebenarnya berada di zona waspada z-score ($-2 \leq z < -1$). Distribusi zona waspada ini berbeda signifikan antar kelompok usia emas ($p < 0,05$). Temuan ini merupakan bukti empiris terkuat dari urgensi sistem AI prediktif SIDIAS yang mampu menangkap risiko tersembunyi yang tidak terdeteksi oleh sistem manual.

Secara keseluruhan, analisis data SIDIAS membuktikan bahwa stunting merupakan masalah multi-dimensional yang dipengaruhi oleh usia, gender, dan kondisi gizi majemuk. Sistem AI berbasis data tabular (Random Forest) maupun data visual (CNN) telah berhasil dikembangkan dan siap mendukung pendeteksian dini stunting secara akurat dan skalabel.

6.2 Rekomendasi (Actionable Insights)

Berdasarkan temuan analisis, berikut rekomendasi strategis dan taktis untuk manajemen instansi kesehatan dan pengembangan SIDIAS lebih lanjut:

1. **Prioritaskan intervensi pada usia 18–30 bulan:** Program suplementasi gizi, pemantauan tumbuh kembang intensif, dan edukasi orang tua harus difokuskan pada rentang usia kritis ini. Alokasi sumber daya posyandu perlu disesuaikan dengan temuan beban stunting terbesar pada kelompok ini.
2. **Implementasikan strategi intervensi berbasis gender:** Protokol pemantauan dan edukasi yang mempertimbangkan perbedaan kerentanan antara balita laki-laki dan perempuan perlu dikembangkan oleh puskesmas

dan posyandu sebagai panduan tindakan yang lebih presisi.

3. **Adopsi sistem z-score otomatis berbasis WHO LMS:** StuntingCalculator yang telah divalidasi dapat langsung diintegrasikan ke dalam alur kerja posyandu untuk menggantikan perhitungan manual yang rentan error, meningkatkan akurasi dan efisiensi kader kesehatan.
4. **Perluas cakupan skrining ke zona waspada:** Sistem SIDIAS perlu dikonfigurasi untuk secara aktif memberikan notifikasi kepada kader posyandu ketika seorang balita berada di zona waspada (z-score -2 s/d -1) meskipun secara administratif masih 'Normal', untuk memungkinkan intervensi preventif lebih awal.
5. **Terapkan pendekatan penanganan gizi terpadu:** Temuan ko-morbiditas tinggi mengindikasikan bahwa program penanganan stunting harus mengintegrasikan pemantauan BB/U dan BB/TB secara simultan, bukan hanya TB/U. Rekomendasi menu gizi dalam SIDIAS perlu mencakup multi-aspek malnutrisi.
6. **Kembangkan modul Random Forest sebagai lini pertama deteksi:** Model Random Forest yang menggunakan data tabular (hanya 6 fitur antropometri) terbukti efisien dan dapat dijalankan bahkan di kondisi konektivitas rendah, menjadikannya kandidat ideal untuk implementasi PWA offline-first SIDIAS.
7. **Tingkatkan dataset citra untuk CNN:** Untuk meningkatkan akurasi model CNN, disarankan pengumpulan dataset gambar yang lebih representatif secara demografis (mencakup variasi etnis, pencahayaan, dan kondisi lapangan) guna memitigasi potensi bias demografis yang teridentifikasi dalam analisis SWOT.

REFERENSI & LAMPIRAN

Tuliskan semua daftar pustaka, sumber dataset publik, dokumentasi modul resmi, tautan repositori kode GitHub, serta tautan menuju aplikasi Streamlit Cloud aktif yang dibuat.

Daftar Pustaka & Sumber Dataset

Dataset utama dan referensi ilmiah yang digunakan dalam proyek SIDIAS:

1. WHO Child Growth Standards — Length/Height-for-Age, Weight-for-Age, Weight-for-Length/Height — Tables: z-scores. World Health Organization, Geneva. <https://www.who.int/tools/child-growth-standards/standards>
2. Deteksi Stunting Object Detection Model — Roboflow Dataset (mnt-bgmps). Roboflow Universe. <https://roboflow.com>
3. Dataset Stunting Balita — Data tabular 40.071 rekaman balita usia 0–60 bulan. Kaggle Public Dataset.
4. World Health Organization (2006). WHO Child Growth Standards: Methods and Development. WHO Press, Geneva.
5. Kemenkes RI (2023). Hasil Survei Status Gizi Indonesia (SSGI) 2022. Badan Kebijakan Pembangunan Kesehatan.
6. Pedoman Surveilans Gizi — Standar Antropometri Penilaian Status Gizi Anak. Permenkes RI Nomor 2 Tahun 2020.

Dokumentasi Teknis

7. Tensorflow Documentation — Keras Functional API: <https://www.tensorflow.org/guide/keras>
8. Scikit-learn Documentation — RandomForestClassifier: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
9. Streamlit Documentation: <https://docs.streamlit.io>
10. Pandas Documentation — Data Wrangling: <https://pandas.pydata.org/docs/>
11. SciPy Stats Documentation — Statistical Tests: <https://docs.scipy.org/doc/scipy/reference/stats.html>

Lampiran — Struktur File Proyek Data Science

Berikut adalah struktur lengkap file dan folder dalam komponen Data Science proyek SIDIAS:

Path / Nama File	Deskripsi
notebooks/data_wrangling.ipynb	Proses pembersihan data end-to-end dari dataset_stunting.csv menjadi dataset_stunting_clean.csv
notebooks/EDA.ipynb	Exploratory Data Analysis: analisis tabular, audit citra Roboflow, validasi Z-score WHO
notebooks/Visualisasi_data.ipynb	Visualisasi explanatory analysis dan jawaban 5 pertanyaan bisnis SMART (Q1–Q5)
notebooks/fe_tabular.ipynb	Feature engineering tabular: IMT, rasio tinggi/usia, encoding, scaling, train-test split
notebooks/image_preprocessing.ipynb	Download Roboflow, reorganisasi folder per kelas, augmentasi gambar MalNutrisi
notebooks/modeling_image.ipynb	Training model CNN 3-kelas (Healthy/MalNutrisi/Stunting) dari scratch menggunakan TensorFlow

notebooks/ab_testing_stunting.ipynb	A/B Testing Random Forest vs CNN: McNemar's Test, Bootstrap CI, Head-to-Head comparison
src/dashboard.py	Dashboard interaktif Streamlit dengan 6 halaman analisis, filter global, dan visualisasi Plotly
src/merge.py	Script penggabungan file CSV sumber WHO menjadi who_reference_master.csv
src/zscore_calculator.py	Kelas StuntingCalculator dengan metode LMS WHO untuk kalkulasi z-score dan deteksi stunting
data/processed/dataset_stunting_clean.csv	Dataset bersih 40.066 baris hasil wrangling, siap untuk EDA dan pemodelan
data/processed/who_reference_master.csv	Tabel LMS referensi WHO gabungan (TB/U, BB/U, BB/TB) untuk semua gender dan usia 0–60 bulan
data/data_fe/tabular_train_features.csv	Training set 32.052 baris dengan 6 fitur ter-scale + target

data/data_fe/tabular_test_features.csv	Test set 8.014 baris dengan 6 fitur ter-scale + target
models/random_forest_stunting_model.pkl	Model Random Forest yang telah dilatih, tersimpan dalam format pickle scikit-learn
models/cnn_stunting_vision_model.h5	Model CNN Computer Vision yang telah dilatih 35 epoch, tersimpan dalam format HDF5 Keras
reports/EDA.html	Laporan EDA yang diekspor otomatis ke format HTML menggunakan nbconvert

Lampiran — Dataset Statistics Summary

Statistik	usia_bulan	berat_badan	tinggi_badan	zscore_tb_u
Count	40.066	40.066	40.066	40.066
Mean	33,02	—	—	-1,74
Min	0	—	—	-7,27

Max	60	—	—	6,60
Std Dev	15,82	—	—	1,18
Laki-laki	21.986	(54,87%)	—	—
Perempuan	18.080	(45,13%)	—	—